

Выравнивание и управление поведением

vlm-recipes · подзадача 3

1. Чего не умеет SFT

SFT максимизирует правдоподобие эталонного ответа. Это учит модель *воспроизводить* хорошие ответы, но ничего не говорит о том, что один ответ лучше другого. Между тем именно это нам и нужно: правильных ответов на «сформулируй мне гипотезу» много, и различаются они оттенком — отдаёт ли модель решение студенту или выдаёт готовый текст.

Формально: SFT видит только положительные примеры и никогда не наблюдает, что *не* следует говорить. Градиент кросс-энтропии поднимает вероятность эталона, но не опускает вероятность правдоподобной альтернативы. Выравнивание по предпочтениям закрывает именно этот пробел.

2. Классический путь: RLHF

Сначала по парам $(y_w \succ y_l)$ обучается модель награды. Вероятность предпочтения задаётся моделью Брэдли–Терри:

$$p(y_w \succ y_l \mid x) = \sigma(r(x, y_w) - r(x, y_l)), \quad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

Затем политика оптимизируется методом PPO при штрафе за отход от исходной модели:

$$\max_{\pi} \mathbb{E}_{x \sim D, y \sim \pi} [r(x, y)] - \beta \text{KL}(\pi(\cdot \mid x) \parallel \pi_{\text{ref}}(\cdot \mid x)).$$

Штраф необходим: без него политика уходит в вырожденные тексты, дающие высокую награду и бессмысленные для человека.

Схема работает, но требует четырёх моделей в памяти (политика, опорная, награды, критик) и капризна в настройке.

3. DPO: вывод

Ключевое наблюдение Rafailov и др. (2023): задача выше решается аналитически, и это позволяет обойтись без модели награды вовсе.

3.1. Шаг 1. Оптимальная политика

Для фиксированного x максимизация по π при KL-штрафе имеет известное решение больцмановского вида:

$$\pi^*(y \mid x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y \mid x) \exp\left(\frac{1}{\beta} r(x, y)\right), \quad Z(x) = \sum_y \pi_{\text{ref}}(y \mid x) e^{r(x, y)/\beta}.$$

3.2. Шаг 2. Обращение

Логарифмируем и выражаем награду через политику:

$$r(x, y) = \beta \log \frac{\pi^*(y \mid x)}{\pi_{\text{ref}}(y \mid x)} + \beta \log Z(x).$$

Награда оказалась *выражена через саму политику*. Отдельная модель награды не нужна: любая политика неявно задаёт награду, и наоборот.

3.3. Шаг 3. Подстановка

Подставляем в Брэдли–Терри. Слагаемое $\beta \log Z(x)$ одинаково для y_w и y_l и сокращается в разности — вместе с ним исчезает единственная неберущаяся сумма:

$$p(y_w \succ y_l | x) = \sigma \left(\beta \log \frac{\pi_\theta(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_\theta(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right).$$

Максимизация правдоподобия этих предпочтений и есть DPO:

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\beta \log \frac{\pi_\theta(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_\theta(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right) \right].$$

3.4. Что делает градиент

Обозначим неявный отступ $\hat{\Delta} = \hat{r}_\theta(x, y_w) - \hat{r}_\theta(x, y_l)$. Тогда

$$\nabla_\theta \mathcal{L}_{\text{DPO}} = -\beta \underbrace{\sigma(-\hat{\Delta})}_{\text{вес примера}} \left[\nabla_\theta \log \pi_\theta(y_w | x) - \nabla_\theta \log \pi_\theta(y_l | x) \right].$$

Вес $\sigma(-\hat{\Delta})$ велик там, где модель *ошибается* в предпочтении, и близок к нулю там, где она уже права. Обучение само концентрируется на трудных парах — отсюда устойчивость метода и малое требуемое число примеров.

4. ORPO: один этап вместо двух

DPO требует предварительного SFT и опорной модели в памяти. ORPO (Hong и др., 2024) обходится без обоих, добавляя к обычному SFT слагаемое с отношением шансов.

Шансы последовательности:

$$\text{odds}_\theta(y | x) = \frac{\pi_\theta(y | x)}{1 - \pi_\theta(y | x)}, \quad \text{OR} = \frac{\text{odds}_\theta(y_w | x)}{\text{odds}_\theta(y_l | x)}.$$

Полная функция потерь:

$$\mathcal{L}_{\text{ORPO}} = \mathcal{L}_{\text{SFT}} - \lambda \log \sigma(\log \text{OR}).$$

Первое слагаемое тянет к эталону, второе разводит выбранный и отвергнутый. Отношение шансов выбрано вместо отношения вероятностей намеренно: оно наказывает мягче и не разрушает уже усвоенное на SFT.

Практический смысл: ORPO даёт один прогон вместо двух и не держит вторую копию модели. При ограниченных ресурсах это метод выбора, а качество сопоставимо с SFT + DPO.

5. SimPO: без опорной модели

Meng и др. (2024) замечают, что неявная награда DPO не согласована с тем, чем на самом деле оценивается генерация. Модель порождает последовательности, максимизируя *среднюю* логвероятность, тогда как награда DPO — сумма по токенам, и потому систематически предпочитает длинные ответы.

SimPO нормирует награду на длину и обходится без опорной модели:

$$r_{\text{SimPO}}(x, y) = \frac{\beta}{|y|} \log \pi_\theta(y | x), \quad \mathcal{L} = -\log \sigma(r(x, y_w) - r(x, y_l) - \gamma).$$

Порог $\gamma > 0$ требует, чтобы выбранный превосходил отвергнутого не просто, а с запасом. Побочный эффект — метод не раздувает длину ответов, характерную для DPO.

6. КТО: когда пар нет

Собрать пары дорого: нужно два ответа на один промпт и сравнение между ними. КТО (Ethayarajh и др., 2024) обходится одиночными примерами с бинарной меткой «хорошо» или «плохо».

6.1. Конструкция

Неявная награда та же, что в DPO, — логарифм отношения политики к опорной:

$$r_{\theta}(x, y) = \log \frac{\pi_{\theta}(y | x)}{\pi_{\text{ref}}(y | x)}.$$

Вторую половину пары заменяет **точка отсчёта** z_0 — среднее отклонение политики от опорной, оцениваемое по батчу. Технически это KL-дивергенция, посчитанная на перемешанных парах: ответ y' берётся от чужого промпта, чтобы оценка не зависела от конкретного примера:

$$z_0 = \text{KL}(\pi_{\theta}(y' | x) \| \pi_{\text{ref}}(y' | x)).$$

Величина z_0 трактуется как константа и в градиенте не участвует.

6.2. Функция ценности

Ценность ответа измеряется относительно z_0 , причём знак сравнения зависит от метки:

$$v(x, y) = \begin{cases} \lambda_D \sigma(\beta(r_{\theta}(x, y) - z_0)), & y \text{ помечен «хорошо»}, \\ \lambda_U \sigma(\beta(z_0 - r_{\theta}(x, y))), & y \text{ помечен «плохо»}. \end{cases}$$

Для хорошего ответа награда должна *превышать* точку отсчёта, для плохого — *отставать* от неё. Функция потерь — недобор ценности:

$$\mathcal{L}_{\text{КТО}} = \mathbb{E}_{x, y \sim D} [\lambda_y - v(x, y)],$$

где λ_y равно λ_D или λ_U в зависимости от метки.

Сигмоида здесь играет роль функции ценности из теории перспектив Канемана и Тверски: она вогнута на приобретениях и выпукла на потерях, то есть отдача убывает по мере удаления от точки отсчёта в обе стороны.

6.3. Почему пара не нужна

Сопоставим с DPO. Там ответ сравнивается с *конкретным* отвергнутым:

$$\hat{r}_{\theta}(x, y_w) - \hat{r}_{\theta}(x, y_l).$$

В КТО ответ сравнивается со *средним* поведением модели:

$$r_{\theta}(x, y) - z_0.$$

Точка отсчёта z_0 заменяет вторую половину пары. Сравнить есть с чем, даже когда про каждый пример известно только «хорошо» или «плохо»: вместо «лучше ли этот ответ того» задаётся вопрос «лучше ли этот ответ того, что модель делает в среднем».

6.4. Асимметрия

Веса λ_D и λ_U различны, и обычно $\lambda_U > \lambda_D$. Формально это из теории перспектив: потери переживаются острее приобретений. Практически же это рычаг под несбалансированные данные. Жалоб на ответы всегда меньше, чем лайков, и больший вес на «плохих» примерах компенсирует перекос — авторы рекомендуют подбирать отношение $\lambda_D n_D / \lambda_U n_U$ в диапазоне от 1 до 4/3, где n_D и n_U — число хороших и плохих примеров.

Отсюда главное практическое следствие: данные можно собирать из продакшена. Лайк или жалоба на ответ уже является меткой, и никакой разметки пар не требуется.

7. Сводка

Метод	Данные	Опорная	Когда брать
DPO	пары	да	есть SFT-модель и память на две копии
ORPO	пары	нет	один этап, ограниченные ресурсы
SimPO	пары	нет	важна длина ответа
KTO	метки	да*	пары собрать дорого

* KTO использует опорную модель, но допускает несбалансированные данные.

8. Векторы управления

Отдельный класс приёмов: изменение поведения *без обучения вовсе*.

8.1. Гипотеза линейного представления

Эмпирически установлено, что абстрактные свойства текста — тональность, правдивость, готовность отказать — кодируются в пространстве активаций приблизительно линейно: существует направление v , сдвиг вдоль которого усиливает свойство.

Оценка направления — разность средних по двум контрастным множествам:

$$v_\ell = \frac{1}{|P|} \sum_{p \in P} h_\ell(p) - \frac{1}{|N|} \sum_{n \in N} h_\ell(n),$$

где $h_\ell(\cdot)$ — активация на слое ℓ , усреднённая по позициям. Применение при генерации:

$$h_\ell \leftarrow h_\ell + s \frac{v_\ell}{\|v_\ell\|}.$$

8.2. Практика

Нормировка делает коэффициент s сопоставимым между моделями и слоями. Слой берётся из середины сети: ранние кодируют поверхностную форму, поздние — конкретные токены, абстрактные свойства живут между ними. Значения s выше 3–4 у большинства моделей разрушают связность.

Главное практическое следствие: если вектор не даёт эффекта ни при каком s , то и дообучение на тех же примерах, скорее всего, не поможет — свойство не выделяется линейно, и проблема в постановке задачи. Это самая дешёвая проверка достижимости поведения: десятки пар и один проход вместо дней сбора данных.

9. Порядок применения

Приёмы упорядочены по стоимости; двигаться следует сверху вниз и останавливаться, как только результат достигнут.

Приём	Стоимость	Ограничение
системный промпт	0	перебивается текстом пользователя
префилл ответа	0	задаёт форму, не содержание
грамматика при декодировании	0	гарантирует формат, не факты
модель-судья	+1 вызов	удвоенная задержка
вектор управления	часы	грубый, сдвигает поведение целиком
SFT	дни	нужны эталонные ответы
DPO / ORPO	дни	нужны пары предпочтений

Отдельно стоит помнить, что значительная часть правил вообще не должна доходить до модели. Запрет на действие закрывается тем, что инструмента не существует; проверяемый факт — детерминированной проверкой в коде; формат — грамматикой при декодировании. Модели следует оставлять только то, что требует понимания смысла.

10. Префилл

Приём, недооценённый чаще прочих. Начало ответа задаётся принудительно, и генерация продолжает написанное:

```
messages = [{"role": "user", ...},
             {"role": "assistant", "content": "Уточняющий вопрос:"}]
apply_chat_template(messages, add_generation_prompt=False)
```

Флаг выключен: служебные токены начала реплики уже поставлены шаблоном.

Механизм отличается от инструкции принципиально. Инструкция входит в условие $x_{<t}$ наравне с текстом пользователя и конкурирует с ним. Префилл же *фиксирует* первые токены ответа, то есть меняет саму точку, из которой разворачивается авторегрессия. Модель не решает, задавать ли уточняющий вопрос — она уже его задаёт.