

Дообучение и выравнивание

SFT, LoRA и предпочтения: математика и практика

vlm-recipes

Две разные задачи

Дообучение под свою предметную область распадается надвое.

Научить форме

Воспроизводить эталонный ответ:
стиль, структура, дисциплина
вызова инструментов.

Это SFT.

Научить различать

Предпочитать один хороший ответ
другому хорошему.

Это выравнивание.

Второе не следует из первого. Разберём почему — и что с этим делать.

Что модель делает на самом деле

Функция одного вида: последовательность токенов на входе, распределение над следующим токеном на выходе.

$$p_{\theta}(\cdot \mid x_1, \dots, x_{t-1}) \in \Delta^{|V|}$$

Больше ничего. Диалог, вызов инструментов, следование инструкции — надстройка над этим единственным действием.

Всё дообучение сводится к двум вопросам: на каких токенах считается градиент и в каком подпространстве разрешено двигать веса.

Что оптимизируется

Отрицательный логарифм правдоподобия — кросс-энтропия по всей последовательности:

$$\mathcal{L}(\theta) = - \sum_{t=1}^T \log p_{\theta}(x_t \mid x_{<t})$$

Проблема: сумма идёт по всем позициям — включая вопрос пользователя и результаты вызовов инструментов.

Модель, обученная так, учится порождать вопросы пользователя и выдумывать вывод инструментов.

Маскирование

Сумма ограничивается множеством A позиций реплик ассистента:

$$\mathcal{L}_{\text{SFT}}(\theta) = -\frac{1}{|A|} \sum_{t \in A} \log p_{\theta}(x_t \mid x_{<t})$$

Существенно: $x_{<t}$ по-прежнему включает весь контекст. Маскирование убирает позиции из потерь, но не из обусловливания.

Технически — значение -100 в метках, которое `cross_entropy` пропускает.

Диагностика: если доля обучаемых токенов $|A|/T$ измеряется единицами процентов, почти весь бюджет батча уходит на проход без градиента.

Почему нельзя дообучать всё

Для AdamW со смешанной точностью, P параметров:

веса bf16	$2P$
мастер-копия fp32	$4P$
градиенты	$2P$
моменты m, v	$8P$
итого	$\approx 16P$ байт

Для $P = 9 \cdot 10^9$ — около 144 ГБ, без учёта активаций.

Все методы ниже атакуют разные слагаемые этой суммы.

LoRA: конструкция

Наблюдение: приращение ΔW , нужное для адаптации к узкой задаче, хорошо приближается матрицей малого ранга.

$$\Delta W = BA, \quad B \in \mathbb{R}^{d \times r}, \quad A \in \mathbb{R}^{r \times k}, \quad r \ll \min(d, k)$$

$$h = W_0 x + \gamma B A x, \quad \gamma = \frac{\alpha}{r}$$

Параметров: $r(d + k)$ вместо dk . При $d = k = 4096$, $r = 32$ — в 64 раза меньше.

Замороженные W_0 не требуют ни градиентов, ни моментов. Три слагаемых из четырёх исчезают.

Инициализация: почему $B = 0$

A случайное, B нулевое $\Rightarrow \Delta W = 0$ на старте: модель выходит ровно из претрейна.

Градиенты, при $g = \partial L / \partial h$:

$$\frac{\partial L}{\partial B} = \gamma g (Ax)^{\top}, \quad \frac{\partial L}{\partial A} = \gamma B^{\top} g x^{\top}$$

Обнуляя одну матрицу, вы убиваете градиент по другой. Обе односторонние схемы обучаются — зеркально друг другу.

Сломана только двусторонняя: обе нулевые $\Rightarrow$ оба градиента нулевые навсегда.

Масштаб: почему α/r плох при больших рангах

Элемент произведения — сумма r слагаемых:

$$(BA)_{ij} = \sum_{s=1}^r B_{is}A_{sj}, \quad \text{Var} [(BA)_{ij}] \approx r \sigma_B^2 \sigma_A^2$$

Среднеквадратичная величина растёт как $\sqrt{r}$ — случайное блуждание, знаки частично гасятся. С множителем $\gamma = \alpha/r$:

$$\gamma \cdot \sqrt{r} \sigma_B \sigma_A = \frac{\alpha \sigma_B \sigma_A}{\sqrt{r}} \xrightarrow{r \rightarrow \infty} 0$$

Вклад адаптера затухает. Поднимая ранг, вы одновременно глушите адаптер. Правильный масштаб — $\gamma = \alpha/\sqrt{r}$, это rsLoRA.

DoRA: разделение величины и направления

При полном дообучении норма столбца и его направление меняются независимо. LoRA такой свободы не даёт: одно приращение BA управляет обоими.

$$W = m \odot \frac{V}{\|V\|_c} \quad \implies \quad W' = m \odot \frac{W_0 + BA}{\|W_0 + BA\|_c}$$

Обучаются m , A , B . Нормировка развязывает две степени свободы.

На низких рангах ($r \leq 16$) устойчиво обходит LoRA. Цена — вычисление нормы на каждом шаге, около 20% скорости.

QLoRA: квантование базы

Веса сети распределены приблизительно нормально — равномерная сетка `int4` тратит разрешение на хвосты.

NF4 строит уровни как квантили нормального распределения:

$$q_i \propto Q_{\mathcal{N}}\left(\frac{i + 0.5}{2^b}\right)$$

Блоки по 64 со своим масштабом; двойное квантование сжимает и масштабы до $\approx 0,127$ бита на параметр.

$$h = \text{dequant}_{\text{bf16}}(W^{\text{NF4}})_x + \gamma \text{BA}x$$

Умножение всё равно в `bf16` — QLoRA экономит память, но не ускоряет. Брать, только когда `bf16`-база не помещается.

Сводка: что выбрать

Метод	Когда	Цена
full	максимум качества, ресурсы есть	16Р байт памяти
lora	базовый выбор	г выше 32 бесполезен
rs_lora	всегда вместо lora	нет
dora	низкие ранги, тонкий стиль	−20% скорости
qlora	база не влезает в bf16	медленнее lora
galore	полноранговое при ограниченной памяти	SVD раз в N шагов

Передний край: LoRA+ (разные lr для A и B), PiSSA (инициализация главными компонентами W_0), VeRA (общие замороженные A, B), Spectrum и LISA (выбор подмножества слоёв).

Чего не умеет SFT

SFT максимизирует правдоподобие эталонного ответа. Это учит воспроизводить хорошие ответы.

Но правильных ответов на один вопрос много, и различаются они оттенком.

SFT видит только положительные примеры и никогда не наблюдает, чего говорить не следует. Градиент поднимает вероятность эталона, но не опускает вероятность правдоподобной альтернативы.

Пример: оба ответа грамотные

Запрос: «Сформулируй мне гипотезу для диплома»

Выбранный

Гипотеза вырастает из проблемы, а её в работе пока нет. Какое противоречие вы заметили?

Отвергнутый

Гипотеза: внедрение дистанционного формата приводит к снижению успеваемости студентов первого курса.

Второй ответ грамотен, уместен и звучит компетентно. Он нарушает одно: содержательное решение принимает студент.

Для SFT эти два ответа неразличимы: он видит только первый и не знает, что второй существует.

Классический путь: RLHF

По парам $(y_w \succ y_l)$ обучается модель награды. Вероятность предпочтения — модель Брэдли–Терри:

$$p(y_w \succ y_l \mid x) = \sigma(r(x, y_w) - r(x, y_l))$$

Затем политика оптимизируется при KL-штрафе:

$$\max_{\pi} \mathbb{E}_{x \sim D, y \sim \pi} [r(x, y)] - \beta \text{KL}(\pi(\cdot \mid x) \parallel \pi_{\text{ref}}(\cdot \mid x))$$

Штраф необходим: без него политика уходит в вырожденные тексты.

Цена: четыре модели в памяти (политика, опорная, награды, критик) и капризная настройка.

ДРО, шаг 1: оптимальная политика

Задача выше решается аналитически. Для фиксированного x решение бoльцмановского вида:

$$\pi^*(y \mid x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y \mid x) \exp\left(\frac{1}{\beta} r(x, y)\right)$$

$$Z(x) = \sum_y \pi_{\text{ref}}(y \mid x) e^{r(x,y)/\beta}$$

Нормировочная сумма $Z(x)$ берётся по всем возможным текстам — посчитать её нельзя. Пока это выглядит тупиком.

Логарифмируем и выражаем награду через политику:

$$r(x, y) = \beta \log \frac{\pi^*(y \mid x)}{\pi_{\text{ref}}(y \mid x)} + \beta \log Z(x)$$

Награда оказалась выражена через саму политику. Отдельная модель награды не нужна: любая политика неявно задаёт награду, и наоборот.

DPO, шаг 3: подстановка

Подставляем в Брэдли–Терри. Слагаемое $\beta \log Z(\mathbf{x})$ одинаково для y_w и y_l — сокращается в разности вместе с неберущейся суммой:

$$p(y_w \succ y_l \mid \mathbf{x}) = \sigma \left(\beta \log \frac{\pi_\theta(y_w \mid \mathbf{x})}{\pi_{\text{ref}}(y_w \mid \mathbf{x})} - \beta \log \frac{\pi_\theta(y_l \mid \mathbf{x})}{\pi_{\text{ref}}(y_l \mid \mathbf{x})} \right)$$

Максимизация правдоподобия предпочтений:

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E} \left[\log \sigma \left(\beta \log \frac{\pi_\theta(y_w \mid \mathbf{x})}{\pi_{\text{ref}}(y_w \mid \mathbf{x})} - \beta \log \frac{\pi_\theta(y_l \mid \mathbf{x})}{\pi_{\text{ref}}(y_l \mid \mathbf{x})} \right) \right]$$

Что делает градиент DPO

Обозначим неявный отступ $\hat{\Delta} = \hat{r}_{\theta}(x, y_w) - \hat{r}_{\theta}(x, y_l)$:

$$\nabla_{\theta} \mathcal{L}_{\text{DPO}} = -\beta \underbrace{\sigma(-\hat{\Delta})}_{\text{вес примера}} \left[\nabla_{\theta} \log \pi_{\theta}(y_w | x) - \nabla_{\theta} \log \pi_{\theta}(y_l | x) \right]$$

Вес $\sigma(-\hat{\Delta})$ велик там, где модель ошибается в предпочтении, и близок к нулю там, где она уже права.

Обучение само концентрируется на трудных парах. Отсюда устойчивость метода и малое требуемое число примеров.

ORPO: один этап вместо двух

DPO требует предварительного SFT и опорной модели в памяти. ORPO обходится без обоих.

Шансы последовательности и их отношение:

$$\text{odds}_{\theta}(y \mid x) = \frac{\pi_{\theta}(y \mid x)}{1 - \pi_{\theta}(y \mid x)}, \quad \text{OR} = \frac{\text{odds}_{\theta}(y_w \mid x)}{\text{odds}_{\theta}(y_l \mid x)}$$

$$\mathcal{L}_{\text{ORPO}} = \mathcal{L}_{\text{SFT}} - \lambda \log \sigma(\log \text{OR})$$

Первое слагаемое тянет к эталону, второе разводит выбранный и отвергнутый.

Отношение шансов выбрано вместо отношения вероятностей намеренно: наказывает мягче и не разрушает усвоенное на SFT.

SimPO: без опорной модели

Неявная награда DPO — сумма по токенам, а генерация максимизирует среднюю логвероятность. Рассогласование: DPO систематически предпочитает длинные ответы.

$$r_{\text{SimPO}}(\mathbf{x}, y) = \frac{\beta}{|y|} \log \pi_{\theta}(y \mid \mathbf{x}), \quad \mathcal{L} = -\log \sigma(r(\mathbf{x}, y_w) - r(\mathbf{x}, y_l) - \gamma)$$

Награда нормирована на длину, опорная модель не нужна.

Порог $\gamma > 0$ требует превосходства с запасом.

Побочный эффект — метод не раздувает длину ответов.

КТО: конструкция

Неявная награда — та же, что в DPO:

$$r_{\theta}(x, y) = \log \frac{\pi_{\theta}(y \mid x)}{\pi_{\text{ref}}(y \mid x)}$$

Вторую половину пары заменяет точка отсчёта — среднее отклонение политики от опорной, оцениваемое по батчу на перемешанных парах:

$$z_0 = \text{KL}(\pi_{\theta}(y' \mid x) \parallel \pi_{\text{ref}}(y' \mid x))$$

z_0 считается как константа и в градиенте не участвует.

КТО: функция ценности

Ценность ответа измеряется относительно z_0 , и знак сравнения зависит от метки:

$$v(x, y) = \begin{cases} \lambda_D \sigma(\beta(r_\theta(x, y) - z_0)), & \text{у помечен «хорошо»} \\ \lambda_U \sigma(\beta(z_0 - r_\theta(x, y))), & \text{у помечен «плохо»} \end{cases}$$

$$\mathcal{L}_{\text{КТО}} = \mathbb{E}_{x, y \sim D} [\lambda_y - v(x, y)]$$

Для хорошего ответа награда должна превышать z_0 , для плохого — отставать от неё. Сигмоида играет роль функции ценности из теории перспектив: вогнута на приобретениях, выпукла на потерях.

КТО: почему пара не нужна

DPO

Ответ сравнивается с конкретным отвергнутым:

$$\hat{r}(y_w) - \hat{r}(y_l)$$

КТО

Ответ сравнивается со средним поведением модели:

$$r_\theta(x, y) - z_0$$

Точка отсчёта z_0 заменяет вторую половину пары. Сравнить есть с чем, даже когда про каждый пример известно только «хорошо» или «плохо».

Асимметрия $\lambda_U > \lambda_D$ — из теории перспектив: потери переживаются острее приобретений. Практически это ещё и рычаг под несбалансированные данные — жалоб обычно меньше, чем лайков, и вес компенсирует перекос.

Отсюда главное следствие: данные можно собирать из продакшена. Лайк или жалоба уже является меткой.

Сводка методов выравнивания

Метод	Данные	Опорная	Когда брать
DPO	пары	да	есть SFT-модель и память на две копии
ORPO	пары	нет	один этап, ограниченные ресурсы
SimPO	пары	нет	важна длина ответа
KTO	метки	да	пары собрать дорого

Векторы управления: без обучения вовсе

Абстрактные свойства ответа кодируются в активациях приблизительно линейно. Направление — разность средних по контрастным множествам:

$$v_\ell = \frac{1}{|P|} \sum_{p \in P} h_\ell(p) - \frac{1}{|N|} \sum_{n \in N} h_\ell(n), \quad h_\ell \leftarrow h_\ell + s v_\ell$$

Десятки пар и один проход — минуты вместо дней.

Если вектор не даёт эффекта ни при каком s , свойство не выделяется линейно, и дообучение на тех же примерах скорее всего тоже не поможет. Самая дешёвая проверка достижимости.

Лестница приёмов по стоимости

Приём	Стоимость	Ограничение
системный промпт	0	перебивается текстом пользователя
префилл ответа	0	задаёт форму, не содержание
грамматика при декодировании	0	гарантирует формат, не факты
модель-судья	+1 вызов	удвоенная задержка
вектор управления	часы	грубый, сдвигает поведение целиком
SFT	дни	нужны эталонные ответы
DPO / ORPO	дни	нужны пары предпочтений

Двигаться сверху вниз и останавливаться, как только результат достигнут.

Итог

1. SFT учит форме. Ключевая деталь — маскирование: градиент только по репликам ассистента.
2. LoRA делает это выполнимым. rsLoRA — дефолт, масштаб $\alpha/\sqrt{r}$ вместо α/r снимает потолок по рангу.
3. Выравнивание учит различать. DPO выводится из RLHF аналитически: награда выражается через саму политику, $Z(x)$ сокращается.
4. Порядок работ: приёмы без обучения $\rightarrow$ вектор управления как проверка достижимости $\rightarrow$ SFT $\rightarrow$ выравнивание. Каждый шаг может показать, что следующий не нужен.