

Выбор модели

vlm-recipes · подзадача 1

1. Что на самом деле требуется

В архитектуре проекта **Skill** — это **механизм подстановки в контекст**, а не способность модели. Методику работы с гипотезой модель получает через `select_skill`, знать её заранее не обязана.

Значит, требования к модели узкие и измеримые:

1. точно исполняет инструкцию, поданную в контексте;
2. вовремя вызывает инструмент и вовремя *перестает* вызывать;
3. держит формат ответа, который разбирается программно;
4. пригодна к дообучению.

Предметные знания проверять не нужно — они приходят из Knowledge. Ресурсы под инференс и обучение здесь тоже не рассматриваются: они меняются от квартала к кварталу, а критерии — нет.

2. Почему семейство Qwen

Лицензия. У плотных моделей Qwen — Apache 2.0, без ограничений на дообучение, внедрение и распространение производных. У Llama и Gemma лицензии с оговорками, которые для внедрения существенны. Внутри самой линейки Qwen лицензия различается: Qwen3.8-27B — Apache 2.0, Qwen3.8-Flash-Next — qwen-community-1.0; смотреть в карточке.

Вызов инструментов обучен, а не имитируется. В `chat_template` есть ветка по `tools`: описания функций подставляются в том формате, в котором модель их видела при обучении. У моделей без такой ветки вызов приходится просить текстом и разбирать вручную, надёжность заметно ниже.

Единая линейка. Текстовые и мультимодальные модели одного поколения имеют общий шаблон диалога и формат данных. Переход между размерами — замена одной строки; переход в другое семейство — переписывание коллатора и перепроверка всего заново.

Русский язык. Токенизация экономнее, чем у Llama, качество выше среднего по открытым моделям. На длинном контексте экономия токенов переходит прямо в память и деньги.

Состояние на сентябрь 2026. Qwen3.7 вышли только по API (3.7-Max, 3.7-Plus). Открытые веса Qwen3.8 — август 2026: Qwen3.8-27B (плотная), Qwen3.8-Flash-Next (125B MoE, 6B активных), Qwen3.8-2.4T-A95B. Все гибридные, глубина рассуждения регулируется `reasoning_effort`. Из предыдущего поколения открыты Qwen3.6-27B и Qwen3.6-35B-A3B; Qwen3.5-9B — младшая плотная модель, на ней собраны ноутбуки.

3. Размер: что он решает, а что нет

Размер задаёт *потолок* качества. Дообучение определяет, насколько модель к этому потолку приблизится *на вашей задаче*. Отсюда правило, которое стоит принять до сравнения моделей:

Дообученная модель на 7–9B на узкой задаче обгоняет модель на 70B без дообучения — почти всегда для правил поведения и формата, почти никогда для сложного многоступенчатого рассуждения.

Класс	Роль
3–4B	судья в гардрейлах, классификация, отладка пайплайна. Не для основной роли: держит инструкцию хуже, чем нужно агенту
7–9B	рабочая модель для узкой предметной задачи после дообучения. Оптимум по соотношению качества к стоимости итерации
27–32B	заметный прирост на рассуждении и длинном контексте. Имеет смысл, когда 9B упёрлась в потолок качества, а не раньше
70B и выше	когда качество решает, а ресурсы есть. Дообучение только распределённое

Практический порядок: отладить пайплайн и данные на 3–4B, вести основную работу на 7–9B, подниматься выше только по результатам замера, а не априори.

4. Где смотреть: бенчмарки и дашборды

Общий балл на лидерборде почти бесполезен: он усредняет несравнимое. Ниже семь источников, на которых по состоянию на сентябрь 2026 года есть последние Qwen. Цифры из карточек моделей — самоотчёт.

Источник	Метрика	Qwen 3.7 / 3.8
τ^3 -Banking, bench	τ^2 - pass@1 по состоянию базы, усреднён по повторам; в τ^2 — pass ^k	3.8 Max 51.3 %, второе место
IFBench	accuracy 0–1; преемник IFEval	3.8 Max 0.828, Flash-Next 0.813, 27B 0.795, 3.7 Max и Plus 0.791
MCP-Mark	pass rate на реальных MCP-серверах	3.7 Max 0.608, 3.7-Plus 0.587, 3.6-35B-A3B 0.370; 3.8 пока нет
MCP-Atlas	pass rate, задача зачтена при $\geq 75\%$ утверждений	таблица от апреля 2026, Qwen нет
Terminal-Bench 2.1	pass@1, три прогона, харнесс Terminus 2	3.8-27B 73.0 по карточке
Agent Arena	поведенческие сигналы на реальных агентных задачах	3.8 Max и Flash-Next с августа
BFCL V4	AST-accuracy; irrelevance / relevance; multi-turn	таблица от 12 апреля 2026, новых Qwen нет

4.1. Политика и инструменты вместе

τ^3 -Banking, τ^2 -bench. <https://artificialanalysis.ai/evaluations/tau3-banking>, <https://github.com/sierra-research/tau2-bench>.

Агент общается с симулированным пользователем, вызывает инструменты и обязан соблюдать политику домена под давлением пользователя. Задача зачтена, если конечное состояние базы совпало с эталоном; качество текста не оценивается. Ближе всего к постановке «агент с Policy». В τ^2 смотреть pass⁴, а не pass¹: разрыв между ними — нестабильность.

4.2. Работа с инструментами

MCP-Mark, MCP-Atlas. <https://llm-stats.com/benchmarks/mcp-mark>, https://labs.scale.com/leaderboard/mcp_atlas.

Задачи на реальных MCP-серверах: найти инструмент, выбрать, вызвать, разобрать результат, довести цепочку. Ближе к «пониманию тулов», чем BFCL. Ограничения: MCP-Atlas не обновлялся с апреля,

MCP-Mark целиком из самоотчётов.

BFCL V4. <https://gorilla.cs.berkeley.edu/leaderboard.html>

Эталонный бенчмарк вызова функций, ответ сравнивается с эталоном по AST. Колонки *irrelevance* (подходящей функции нет, зачтён ответ без вызова) и *relevance* (вызов нужен, был ли он) — та же пара, что *hit* / *false* в наших замерах. Таблица не пополнялась с апреля 2026; код открыт, прогон на своей модели занимает около часа.

Terminal-Bench 2.1. <https://artificialanalysis.ai/evaluations/terminalbench-v2-1>

Длинные задачи в настоящем терминале с программной проверкой; харнесс у всех моделей одинаковый. Меряет доведение цепочки до конца, не отдельный вызов. Смещён в сторону кода.

4.3. Следование инструкциям

IFBench. <https://llm-stats.com/benchmarks/ifbench>

Проверяемые кодом ограничения на ответ, как в IFEval, но новые типы ограничений, которых не было в обучающих данных. IFEval насыщен: у всех сильных моделей за 90. Так же устроены автопроверки по рубрикам голд-сета в *vlmkit/rubric.py*.

4.4. Живой поток задач

Agent Arena. <https://arena.ai>

Запущен в июне 2026. Ранжирует модели на реальных агентных задачах пользователей по поведенческим сигналам: повторы, отклонённые действия, управляемость. Единственный источник с живым потоком задач; методика закрытая.

Что выпало: IFEval (насыщен), Open LLM Leaderboard (заморожен с 2025), AgentBench и GAIA (без новых моделей с 2024), LMArena Text (диалог, не инструменты). Artificial Analysis полезен как агрегатор: Qwen3.8-27B там прогнан на τ^3 -Banking, Terminal-Bench и IFBench.

5. Кто хорош в инструментах

По состоянию на сентябрь 2026 года, семейства, а не версии: версии меняются каждые несколько месяцев.

Qwen 3.6–3.8 — верх открытой части таблиц IFBench и MCP-Mark, вызов инструментов обучен нативно, есть все размеры. Самоотчёт Qwen3.8-27B: IFBench 79.5, Terminal-Bench 2.1 — 73.0, Agents' Last Exam 20.4; Flash-Next выше на всех опубликованных строках.

Kimi K2.6 / K3 (Moonshot) — лидер среди открытых на MCP-Mark и MCP-Atlas, модели крупные.

GLM-5.x (Z.ai) — сильны на MCP-Atlas и в агентном коде.

DeepSeek V4 — сильны в агентном коде и на IFBench, модели крупные.

Muse Glimmer-30B (Meta), **Inkling-Small** (Thinking Machines) — открытые модели среднего размера, конкурирующие с Qwen3.8-27B на IFBench и τ^3 .

Специализированные под вызов функций модели прошлых лет — xLAM, Hermes, ToolACE, Functionary — на BFCL обходили общие модели того же размера, но в диалоге слабее и с 2025 года не обновляются.

Для агента, который не только вызывает инструменты, но и разговаривает со студентом, безопаснее общая модель с нативной поддержкой инструментов, чем узкий специалист по вызовам.

6. Проверка кандидата

`python tools/check_model.py <id>` — веса не качает, работает секунды. Четыре факта, которые нужно увидеть:

Поле	Требуемое значение
квантование	нет
вызов tools	обучен
русский	не меньше 3 символов на токен
лицензия	apache-2.0

Лидерборд отсекает заведомо слабые модели; между оставшимися выбирает собственный замер на своих данных и своём шаблоне — `tools/selfcheck.py` и ноутбуки.

7. Красные флаги

Только квантованные репозитории (-FP8, -NVFP4, -AWQ, -GPTQ). Обучать по ним нельзя. Хуже того, transformers не выдаёт ошибку, а начинает разжимать веса в bf16 — обнаруживается это по неожиданному расходу памяти. Признак в журнале: `Decompressing`.

Нет tools в шаблоне. Для агентского цикла модель годится плохо: формат вызова придётся изобретать и разбирать самому.

Неизвестный model_type. Установленный transformers старше модели. Обновить; если поддержки нет и в основной ветке — дообучение потребует ручной работы с кодом модели.

8. Открытая модель против API

Кандидаты в общей архитектуре проекта — закрытые модели по API. Для них дообучение недоступно или ограничено, а управление поведением сводится к системному промпту.

Смысл ветки с открытой моделью не в том, чтобы догнать их по общему качеству, а в двух вещах, которых API не даёт: **закрепить Policy в весах** и **вмешаться в поведение на уровне активаций**. По этой оси её и следует оценивать.